

FLOPs

Чтобы посчитать FLOPs для всей модели, посчитаем FLOPs для каждого слоя отдельно.

Достаточно известная формула FLOPs для Conv 2d без bias:

$$2 \cdot C_{in} \cdot C_{out} \cdot H_{out} \cdot W_{out} \cdot K_H \cdot K_W \cdot B$$

C_{in} / C_{out} — размерность входных и выходных каналов

H_{out} / W_{out} — размерности выходных изображений

K_H / K_W — размерности ядра

B — размер батча

FLOPs для linear слоев в рекуррентной сети так:

$$2 \cdot B \cdot 512 \cdot 256 + \underbrace{B \cdot 256}_{\text{bias}} + 2 \cdot B \cdot 256 \cdot 100 + \underbrace{B \cdot 100}_{\text{bias}} = 313700 \cdot B$$

Для Global AvgPooling кол-во FLOPs будет:

$$B \cdot 512 \cdot \left(\left(\frac{S}{16} \right)^2 - 1 \right) + \underbrace{B \cdot 512}_{\text{кол-во элементов}} = 2 \cdot B \cdot S^2$$

Так как в ReLU и MaxPool нет сложений или умножений, то мы не будем учитывать их.

Посчитаем оригинальную формулу

$$\text{Conv } 7 \times 7 \rightarrow 2 \cdot 3 \cdot 32 \cdot \left(\frac{S}{2} \right)^2 \cdot 49 \cdot B = 2352 \cdot B \cdot S^2$$

$$\text{Conv } 5 \times 5 \rightarrow 2 \cdot 32 \cdot 64 \cdot \left(\frac{S}{4} \right)^2 \cdot 25 \cdot B = 6400 \cdot B \cdot S^2$$

$$\text{Conv } 3 \times 3 \rightarrow 2 \cdot 64 \cdot 128 \cdot \left(\frac{S}{8} \right)^2 \cdot 9 \cdot B = 2304 \cdot B \cdot S^2$$

$$\text{conv } 1 \times 1 \rightarrow 2 \cdot 256 \cdot 128 \cdot \left(\frac{S}{8}\right)^2 \cdot B = 1024 \cdot B \cdot S^2$$

$$\text{conv } 3 \times 3 \rightarrow 2 \cdot 256 \cdot 256 \cdot \left(\frac{S}{8}\right)^2 \cdot B = 4608 \cdot B \cdot S^2$$

$$\text{conv } 1 \times 1 \rightarrow 2 \cdot 256 \cdot 512 \cdot \left(\frac{S}{16}\right)^2 \cdot B = 1024 \cdot B \cdot S^2$$

$$\text{Теперь сложим всё вместе: } 17714 \cdot B \cdot S^2 + 313700 \cdot B$$

Memory

Всего у нас 1040324 параметров $\rightarrow$ 4161296 байт

Теперь разберём, сколько памяти занимают активации и данные. Ввод занимает $4 \cdot B \cdot 3 \cdot S^2$ байт.

Выход занимает $4 \cdot B \cdot 100$ байт.

Разберём промежуточные выходы у нас в модели:

$$\text{conv } 7 \times 7 \rightarrow 4 \cdot 32 \cdot \left(\frac{S}{2}\right)^2 \cdot B = 32 \cdot S^2 \cdot B \text{ байт} \leftarrow \text{самый большой тензор}$$

$$\text{max pool } 3 \times 3 \rightarrow 4 \cdot 32 \cdot \left(\frac{S}{4}\right)^2 \cdot B = 8 \cdot S^2 \cdot B \text{ байт}$$

$$\text{conv } 5 \times 5 \rightarrow 4 \cdot 64 \cdot \left(\frac{S}{4}\right)^2 \cdot B = 16 \cdot S^2 \cdot B \text{ байт}$$

$$\text{conv } 3 \times 3 \rightarrow 4 \cdot 128 \cdot \left(\frac{S}{8}\right)^2 \cdot B = 8 \cdot S^2 \cdot B \text{ байт}$$

$$\text{conv } 1 \times 1 \rightarrow 4 \cdot 256 \cdot \left(\frac{S}{8}\right)^2 \cdot B = 16 \cdot S^2 \cdot B \text{ байт}$$

$$\text{conv } 3 \times 3 \rightarrow 4 \cdot 256 \cdot \left(\frac{S}{16}\right)^2 \cdot B = 4 \cdot S^2 \cdot B \text{ байт}$$

$$\text{conv } 1 \times 1 \rightarrow 4 \cdot 512 \cdot \left(\frac{S}{16}\right)^2 \cdot B = 8 \cdot S^2 \cdot B \text{ байт}$$

$$\text{Global Avg Pooling} \rightarrow 4 \cdot 512 \cdot \frac{1}{16} \cdot B = 2048 \cdot B \text{ байт}$$

$$\text{Linear } 512 \rightarrow 256 \rightarrow 4 \cdot 256 \cdot B = 1024 \cdot B \text{ байт}$$

$$\text{Linear } 256 \rightarrow 100 \rightarrow 4 \cdot 100 \cdot B = 400 \cdot B \text{ байт}$$

ReLU не считаем,
т.к. inplace=True

Так по памяти пройдёт в Max pool, т.к. в этот момент хранится вход в модель, выход первой свертки, и в max pool ещё дополнительно выделяется $8 \cdot S^2 \cdot B$ байт под ответ.

$$\text{Итоговая формула: } 4161296 + 400 \cdot B + 52 \cdot B \cdot S^2 \text{ байт}$$

Bytes moved

Предположим, что свои не считаем, входы и выходы не кэшируются, тогда посчитаем сколько байт было прочитано и записано. В промпте нужно посчитать кол-во памяти у входов своих. Нужно ещё учесть свои активации и pooling.

$\text{Bytes}(S, B) = 364 \cdot BS^2$ - до записи рез-та GAP

$\text{Bytes}(S, B) = 8592 \cdot B$ - после записи GAP

Всего $\text{Bytes}(S, B) = 364 \cdot BS^2 + 8592 \cdot B + 4161296$ байт

чтение блоков

Latency

Latency складывается из задержек kernel и манипуляций со временем графика данных и подсчёта результата (max, т.к. это идёт параллельно):

$$\text{Latency}(S, B, Q) = Q_k + \max(\text{FLOPs}(S, B) \cdot Q_F, \text{Bytes}(S, B) \cdot Q_B)$$

$$Q = (Q_k, Q_F, Q_B)$$

Energy

Энергия складывается из затрат на активацию, на графики данных, а также базовой мощности на протяжении всей работы GPR:

$$\text{Energy}(S, B, \Theta', \Theta) = \text{Latency}(S, B, \Theta) \cdot \Theta'_L + \\ + \text{FLOPs}(S, B) \cdot \Theta'_F + \text{Bytes}(S, B) \cdot \Theta'_B$$

$$\Theta' = (\Theta'_L, \Theta'_F, \Theta'_B)$$