

Обзор статьи. ZerO Initialization: Initializing Neural Networks with only Zeros and Ones

ИТМО. AI Talent Hub

Кондауров Захар Дмитриевич.
1 курс магистратуры AI Talent Hub

Введение

Проблема случайной инициализации весов модели кроется в дисперсии распределения. Если она будет слишком большой, то может произойти взрыв градиентов, если слишком маленькой, то затухание градиентов.

Чтобы этого избежать, предлагается детерминированная инициализация весов. Подобные методы страдают от “деградации” обучения и низкой обобщающей способности модели, поэтому иногда добавляют некоторую стохастичку, чтобы сохранить dynamical isometry (собственные числа матрицы Якоби матрицы весов находятся близко к 1) и обеспечить корректное поведение градиентов. Однако это добавляет дополнительные подброс значения дисперсии, неправильное значение которой может привести к взрыву градиентов у глубоких нейросетей.

Введение

Авторы статьи предлагают инициализацию ZerO, которая:

- Обеспечивает стабильное обучение глубоких нейросетей без batch norm
- Ранг весов модели повышается по мере обучения, т.е. от примитивного пространства приходит к сложному. Это делает модель более интерпретируемой.
- Итоговая модель получается более разреженной в сравнении с random init
- Обучение модели обладает лучшей воспроизводимостью




Схема модели с ZerO инициализацией. H – матрица Адамара, которая используется для повышения размерности. I – единичная матрица для операций с одним размером входа и выхода, и для понижения размерности каналов

Основная идея

Пусть веса модели будут инициализированы единичной матрицей. Мы знаем как выглядит такая матрица в случае одинакового размера входа и выхода, но для разных размерностей её нужно определить. Пусть Partial Identity Matrix будет следующая матрица:

$$I^* = \begin{cases} (I, \mathbf{0}) & \text{where } I \in \mathbb{R}^{l,l} \text{ and } \mathbf{0} \in \mathbb{R}^{l,r-l} & \text{if } l < r, \\ I & \text{where } I \in \mathbb{R}^{l,l} & \text{if } l = r, \\ (I, \mathbf{0})^\top & \text{where } I \in \mathbb{R}^{r,r} \text{ and } \mathbf{0} \in \mathbb{R}^{r,l-r} & \text{otherwise.} \end{cases}$$

Возникает проблема, что, при повышении размерности, ранг матрицы остаётся прежним, т.е. признаки не переходят в пространство большей размерности. Из этого следует, что пространство признаков сложнее не становиться. Значит, повышение размерности не приносит никакой пользы. Что приводит к вырожденности матриц.

Чтобы это исправить, авторы предлагают в качестве слоёв повышения размерности использовать произведение матрицы Адамара и Partial Identity Matrix. Матрица Адамара:

$$H_m = \begin{pmatrix} H_{m-1} & H_{m-1} \\ H_{m-1} & -H_{m-1} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 & 1 & \dots \\ 1 & -1 & 1 & -1 & \dots \\ 1 & 1 & -1 & -1 & \dots \\ 1 & -1 & -1 & 1 & \dots \\ \vdots & \vdots & \vdots & \vdots & \ddots \end{pmatrix} \in \mathbb{R}^{2^m \times 2^m}.$$

Матрица Адамара поворачивает оси координат так, что они оказываются не выровнены со стандартными координатными осями, а направлены по их диагоналям. Это создаёт условие, при которых векторы имеют разные направление.

Кроме того, инициализация весов подобным образом несёт за собой dynamical isometry, т.к. в матрица Якоби единичной матрицы – единичная матрица. Это также помогает избежать взрыв градиентов.

ZerO инициализация

Объединив предыдущие рассуждения, получился итоговый алгоритм инициализации весов. Стоит отметить, что матрицы, повышающие размерности дополнительно умножаются на нормировочную константу, чтобы признаки не меняли свой масштаб.

Свертки же изначально инициализируются нулями, а центральный срез ядра заполняется по правилу из первого алгоритма. Это обеспечивает стабильность активаций и уменьшает шанс градиентного взрыва/затухания. Также последняя свёртка в residual блоке полностью инициализируется нулями для dynamical isometry. В BatchNorm (BN) bias и scale инициализируются нулём и единицей. В случае без BN, всё заменяется на обучаемый bias и scale.

Также рассматривается инициализация весов для трансформера. Для feed-forward слоёв используется алгоритм 1, W_Q инициализируется единичной матрицей, W_K и W_V инициализируются нулями.

Algorithm 1 *ZerO Initialization.*

Input: a neural network $\mathcal{F}$ with L matrices $W_l \in \mathbb{R}^{P_l \times Q_l}$ for l in $1, \dots, L$. I^* is partial identity matrix defined in Definition [1]. H_m is the Hadamard matrix defined in Definition [2].
For l in $1, \dots, L$:
 If $P_l = Q_l$: $W_l \leftarrow I$ ▷ Identity mapping
 If $P_l < Q_l$: $W_l \leftarrow I^*$ ▷ Propagate the first P_l dimensions
 If $P_l > Q_l$: $W_l \leftarrow c I^* H_m I^*$, where $m = \lceil \log_2(P_l) \rceil$ and $c = 2^{-(m-1)/2}$ ▷ Apply Hadamard matrix

Алгоритм 1. Инициализация линейного слоя

Algorithm 2 *ZerO Initialization on Convolution.*

Input: number of input channels c_{in} , number of output channels c_{out} , odd kernel size k .
Return: a $c_{out} \times c_{in} \times k \times k$ convolutional kernel K .
Let $n \leftarrow \lfloor k/2 \rfloor$
 If $c_{out} = c_{in}$: $K[:, :, n, n] \leftarrow I$
 If $c_{out} < c_{in}$: $K[:, :, n, n] \leftarrow I^*$
 If $c_{out} > c_{in}$: $K[:, :, n, n] \leftarrow c I^* H_m I^*$, where $m = \lceil \log_2(P_l) \rceil$ and $c = 2^{-(m-1)/2}$

Алгоритм 2. Инициализация свёртки

Результаты экспериментов

Результаты экспериментов на датасетах CIFAR-10 и ImageNet модели ResNet-18 и ResNet-50 ZerO Init показал сравнимые со случайной инициализацией метрики. Кроме того, ZerO Init показывает меньшее стандартное отклонение метрики на 10 запусках.

Стоит отметить, что обучение производилось с `learning_rate=0.1`, что нетипично. Также использовался `warm up` первые 5-10 эпох.


Были проведены результаты сравнения с другими способами инициализации, и ZerO побеждает каждый из них, потому что он сохраняет разнообразие признаков.

Также ZerO протестирован на ultra deep нейросетях без BN, который может повлиять на стабильность обучения для таких глубоки нейросетей. В сравнении с другими способами инициализации ZerO показывает более стабильные матрики.

Кроме того, были эксперименты с над инициализацией слоёв трансформера. И результаты показывают, что на более глубоких сетях ZerO показывает более стабильное обучение и лучше метрики.

Dataset	Model	Initialization	Test Error (mean $\pm$ std)
CIFAR-10	ResNet-18	ZerO Init	5.13 $\pm$ 0.08
		Kaiming Init	5.15 $\pm$ 0.13
		Xavier Init	5.23 $\pm$ 0.16
ImageNet	ResNet-50	ZerO Init	23.43 $\pm$ 0.04
		Kaiming Init	23.46 $\pm$ 0.07
		Xavier Init	23.65 $\pm$ 0.11

ZerO на CIFAR-10 и ImageNet. 10 запусков с разным сидом



Обучение ultra deep ResNet на CIFAR-10 15 эпох

Method	ZerO	ReZero	Fixup	SkipInit	ConstNet	ConstNet*
ResNet-18	5.13	5.20	5.17	5.26	72.39	5.41
ResNet-50	4.53	4.72	4.51	4.63	71.58	4.88

Сравнение ZerO на CIFAR-10 с другими способами инициализации. ConstNet* это ConstNet с non-deterministic GPU операциями. Top-1 test error

Number of layers	2	4	6	8	10	20
Standard	200.44	168.69	154.67	146.43	diverged	diverged
ZerO	192.34	169.73	151.91	149.27	145.62	141.81

Perplexity трансформера с разным количеством слоёв

Low-rank траектория обучения

Авторы статьи также проанализировали ранги матриц весов. В частности Stable Rank, который показывает сколько сингулярных компоненты несут большую часть информации:

$$\|W\|_F^2 / \|W\|_2^2 = \sum_{i=1}^k \sigma_i^2(W) / \sigma_{max}^2(W),$$

Можно заметить, что у ZerO возникает эффект, при котором нейросеть начиная с низкого Stable Rank, и приходит к более высоким значениям. Кроме того, значение Stable Rank для некоторых случаев близко к случайным инициализациям. Это показывает, что модель идёт от простой структуры к более сложной.

Авторы утверждают, что это пример greedy low-rank learning (GLRL). GLRL показывает, что можно искать минимум начиная с более простых матрицы с малым рангом. На графиках Stable Rank показано, как растёт ранг к значениям случайной инициализации. Это может означать, что использование матриц с полным рангом необязательное.

Также были проведены эксперименты с прунингом и Tucker-2 decomposition. В обоих случаях ZerO позволяет сжать нейросеть с меньшими потерями метрики.





График stable rank для разных инициализаций. Сверху ResNet-18 на CIFAR-10. Снизу ResNet-50 на ImageNet. Визуализировался ранг первой свёртки во 2, 3, и 4 residual блоках



Слева направо. Ранг ядер в ResNet-18. Зависимость качества ResNet-18 с ZerO от magnitude-based network pruning. Зависимость качества ResNet-18 с ZerO от Tucker-2 decomposition для свёртки с 512 каналами

Выводы

Предлагаемое решение демонстрирует высокую стабильность метрик, что, как заявляют авторы, может говорить о необязательности случайной инициализации глубоких нейросетей. Также у ZerO можно выделить следующие плюсы:

- Возможность обучать ultra deep networks без BN
- Итоговые матрицы весов получаются низкоранговыми, что может привести к более разреженным матрицам
- Отсутствие случайности при инициализации весов делает эксперименты более воспроизводимыми
- Повышает интерпретируемость нейросетей

Данная статья помогает лучше понять как влияет инициализация весов на модель, а также открывает новые пути для исследования эффективного и интерпретируемого обучения нейросетей.